

周志华 著

MACHINE  
LEARNING

# 机器学习

清华大学出版社

崔磊

QQ: 362626744


E-Mail: leicui@nwu.edu.cn

办公室: 信息学院院楼912

本章课件致谢:  
张腾

本课件版权所有©LAMD, 其他目的需征得本书作者同意

为本书教学目的可免费使用,



---


# 第六章：支持向量机

---

---


# 一个例子

---




# 一个例子

---





# 一个例子

---



# 魔鬼试炼

---




# 大纲

---

- 间隔与支持向量
- 优化问题求解方法
- 核函数
- 软间隔与正则化

# 间隔与支持向量


线性模型：在样本空间中寻找一个超平面，将不同类别的样本分开。






# 间隔与支持向量

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?




# 间隔与支持向量

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?




-A: 应选择“**正中间**”, 容忍性好, 鲁棒性高, 泛化能力最强.


# 间隔与支持向量



(a)




(b)



(c)

# 间隔与支持向量

超平面方程:  $w^\top x + b = 0$



# 支持向量机基本型

□ 最大间隔：寻找参数  $\mathbf{w}$  和  $b$ , 使得  $\gamma$  最大.

$$\begin{aligned} \arg \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



$$\begin{aligned} \arg \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

# 大纲

---

- 间隔与支持向量
- 优化问题求解方法
- 核函数
- 软间隔与正则化

# 优化问题求解方法

- 无约束优化问题，可写为：

$$\min f(x)$$

费马引理  
导数为0

- 有等式约束的优化问题，可写为：

$$\min f(x)$$

$$s. t. h_i(x) = 0, \quad i = 1, 2, \dots, n$$

$$F(x, \lambda) = f(x) + \sum_{k=1}^l \lambda_k h_k(x)$$

拉格朗日乘子法

# 拉格朗日乘子法

## □ 拉格朗日乘子法

- 第一步：引入拉格朗日乘子  $\alpha_i \geq 0$  得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令  $L(\mathbf{w}, b, \boldsymbol{\alpha})$  对  $\mathbf{w}$  和  $b$  的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 第三步：回代

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$



# 解的稀疏性



□ 最终模型:  $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \boxed{\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}} + b$

□ KKT条件:

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

$$y_i f(\mathbf{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的稀疏性: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.



# 求解方法 - SMO

□ 基本思路：不断执行如下两个步骤直至收敛.

- 第一步：选取一对需更新的变量  $\alpha_i$  和  $\alpha_j$ .
- 第二步：固定  $\alpha_i$  和  $\alpha_j$  以外的参数，求解对偶问题更新  $\alpha_i$  和  $\alpha_j$ .

□ 仅考虑  $\alpha_i$  和  $\alpha_j$  时，对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0.$$

用一个变量表示另一个变量，回代入对偶问题可得一个单变量的二次规划，该问题具有闭式解.

□ 偏移项  $b$ ：通过支持向量来确定.

# 小试牛刀

已知三个数据点：正样本 $\mathbf{x}_1 = (3, 3)^\top$ ,  $\mathbf{x}_2 = (4, 3)^\top$ , 负样本 $\mathbf{x}_3 = (1, 1)^\top$ , 求超平面方程。 ( $y_i \in \{+1, -1\}$ )

**求解：**

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

# 大纲

---

□ 间隔与支持向量

□ 对偶问题


□ 核函数

□ 软间隔与正则化

# 线性不可分

- Q: 若不存在一个能正确划分两类样本的超平面, 怎么办?
- A: 将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分.

目标：找到一种变换的方法，也就是  $\phi(x)$



# 核支持向量机

□ 设样本  $\mathbf{x}$  映射后的向量为  $\phi(\mathbf{x})$ , 划分超平面为  $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$ .

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)} - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

只以内积的形式出现

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x})} + b$$

# 核函数

- 基本想法：不显式地设计核映射，而是设计核函数。

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

- Mercer定理(充分非必要)：只要一个对称函数所对应的核矩阵半正定，则它就能作为核函数来使用。

- 常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$



# 大纲

---

□ 间隔与支持向量



□ 对偶问题

□ 核函数

□ 软间隔与正则化

# 软间隔

- Q:现实中, 很难确定合适的核函数使得训练样本在特征空间中线性可分; 同时一个线性可分的结果也很难断定是否是有过拟合造成的.
- A:引入“软间隔”的概念, 允许支持向量机在一些样本上不满足约束.



# 软间隔

---

为了解决该问题，引入松弛因子

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i$$

新的目标函数： $\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$

当C趋近于很大时：意味着分类严格不能有错误

当C趋近于很小时：意味着可以有更大的错误容忍

C是我们需要指定的一个参数！

# 0/1损失函数

- 基本想法：最大化间隔的同时，让不满足约束的样本应尽可能少。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1} (y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) - 1)$$


其中  $l_{0/1}$  是“0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

- 存在的问题：0/1损失函数非凸、非连续，不易优化！

# 替代损失

## 软间隔SVM



替代损失函数数学性质较好, 一般是0/1损失函数的上界

# 软间隔支持向量机

原始问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m. \end{aligned}$$

根据KKT条件可推得最终模型仅与支持向量有关, 也即hinge损失函数依然保持了支持向量机解的稀疏性.

# 正则化

## □ 支持向量机学习模型的更一般形式

$$\min_f \Omega(f) + C \sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$$



结构风险, 描述  
模型的某些性质



经验风险, 描述模型与  
训练数据的契合程度

## □ 通过替换上面两个部分, 可以得到许多其他学习模型

- 对数几率回归(Logistic Regression)
- 最小绝对收缩选择算子(LASSO)
- .....

# 大纲

---

□ 间隔与支持向量

□ 对偶问题

□ 核函数

□ 软间隔与正则化



# Take Home Message

---

- 支持向量机的“最大间隔”思想
- 优化问题求解方法
- 通过向高维空间映射解决线性不可分的问题
- 引入“软间隔”缓解特征空间中线性不可分的问题

# 成熟的SVM软件包

---

- LIBSVM

<http://www.csie.ntu.edu.tw/~cjlin/libsvm/>

- LIBLINEAR

<http://www.csie.ntu.edu.tw/~cjlin/liblinear/>

- SVM<sup>light</sup>、SVM<sup>perf</sup>、SVM<sup>struct</sup>

[http://svmlight.joachims.org/svm\\_struct.html](http://svmlight.joachims.org/svm_struct.html)

- Pegasos

<http://www.cs.huji.ac.il/~shais/code/index.html>